

Propuesta de proyecto de grado

1. Título del Proyecto.

Identificación de factores de riesgo de malnutrición en niños prematuros, evaluados a 12 meses de edad corregida

2. Organización/Grupo de investigación.

El proyecto se desarrolla en colaboración con la Fundación Canguro, organización colombiana líder en investigación y aplicación del Método Madre Canguro (MMC) para el manejo de bebés prematuros y de bajo peso al nacer.

La fundación cuenta con más de 30 años de investigación clínica y seguimiento longitudinal de recién nacidos prematuros, con una base histórica provenientes de programas de seguimiento neonatal. El proyecto cuenta con el acompañamiento de expertos clínicos y académicos vinculados al programa, entre ellos José Tiberio Hernández, quien participa como experto en el dominio del problema y asesor en la interpretación de variables clínicas.

El proyecto se desarrolla en el marco académico de la Maestría en Inteligencia Artificial de la Universidad de los Andes, específicamente en el contexto de proyectos orientados a Machine Learning aplicado a salud.

3. Contexto, problema y Justificación. Impacto esperado.

Anualmente, se registran más de 15 millones de nacimientos pretérmino (gestación menor a 37 semanas). Paralelamente, cerca de 20 millones de recién nacidos presentan bajo peso (inferior a 2.500 g). La prematuridad y el bajo peso al nacer constituyen determinantes críticos de la morbilidad neonatal, siendo responsables de aproximadamente el 35% de los fallecimientos de recién nacidos en el mundo. Los supervivientes enfrentan un pronóstico complejo, con riesgos elevados de secuelas neurológicas, respiratorias y del desarrollo, así como predisposición a enfermedades crónicas.

El objetivo central de este proyecto es utilizar técnicas de aprendizaje de máquina para desarrollar herramientas de soporte al diagnóstico de malnutrición en infantes prematuros. Este sistema debe

tener la capacidad de identificar los factores de mayor influencia en la malnutrición y estimar la probabilidad de desarrollo y los riesgos que desencadenan este estado. El resultado final es una herramienta dotada de una interfaz intuitiva, diseñada para facilitar la interacción y la toma de decisiones del especialista médico.

Con esto en mente, se espera generar un impacto real dentro del mundo médico enfocado al diagnóstico. Dado el alcance, las restricciones y limitaciones de este, se debe generar una herramienta de utilidad para la Fundación Canguro en el proceso de diagnóstico e identificación de la malnutrición promoviendo un incremento en el tratamiento adecuado de todo infante que acceda a la fundación.

4. Objetivos

Objetivo General. Descripción clara y concisa del propósito del proyecto.

Identificar los factores clínicos, perinatales y socio-demográficos asociados a malnutrición en niños prematuros evaluados a los doce meses de edad corregida, utilizando modelos de aprendizaje automático aplicados a datos clínicos del Programa Madre Canguro, analizando la influencia de variables presentes en las primeras fases del desarrollo, con el fin de generar evidencia que contribuya al apoyo en la toma de decisiones clínicas y a la prevención temprana de riesgos nutricionales.

Objetivos Específicos. Listado de objetivos que se desean alcanzar durante el desarrollo del proyecto.

- Caracterizar la población de niños prematuros del Programa Madre Canguro mediante el análisis de variables maternas, perinatales y del desarrollo temprano.
- Analizar la relación entre variables presentes en las primeras fases del desarrollo (embarazo, nacimiento y primeros meses de vida) y el estado nutricional a los 12 meses de edad corregida.
- Desarrollar modelos de aprendizaje automático que permitan estimar la probabilidad de malnutrición en niños prematuros a partir de variables tempranas.
- Identificar las variables con mayor influencia en la predicción de malnutrición mediante técnicas de interpretación de modelos.
- Evaluar el desempeño de los modelos predictivos mediante métricas de clasificación apropiadas para datos clínicos.

5. Estado del arte.

El uso de técnicas de aprendizaje automático para la predicción de parto pretérmino ha crecido significativamente en la última década debido a la disponibilidad de grandes bases de datos clínicos y registros electrónicos de salud. Diversos estudios han explorado modelos de clasificación supervisada para estimar el riesgo de nacimiento prematuro a partir de variables clínicas, demográficas y antecedentes obstétricos. Entre los algoritmos más utilizados se encuentran la regresión logística penalizada, random forest, gradient boosting y redes neuronales, los cuales han mostrado desempeños predictivos moderados a altos, con valores de AUC generalmente entre 0.78 y 0.85 dependiendo del conjunto de variables utilizadas y del momento del embarazo en el que se realiza la predicción (Mennickent et al., 2023; Huang et al., 2024).

En estudios recientes basados en historias clínicas electrónicas y cohortes poblacionales, los modelos de machine learning han demostrado superar o igualar el desempeño de los métodos estadísticos tradicionales cuando existen relaciones no lineales entre variables o interacciones complejas entre factores de riesgo maternos y condiciones del embarazo (Belaghi et al., 2024; Yu et al., 2024). Sin embargo, revisiones sistemáticas han señalado limitaciones importantes en muchos de estos trabajos, incluyendo problemas de sesgo en los datos, falta de validación externa, manejo insuficiente de clases desbalanceadas y limitada interpretabilidad clínica de los modelos, lo que dificulta su adopción en entornos médicos reales (Yang et al., 2023).

En el contexto del cuidado neonatal, el Programa Madre Canguro ha generado una de las cohortes longitudinales más amplias para el estudio de prematuridad y bajo peso al nacer en América Latina. Estudios longitudinales han reportado el seguimiento de más de 57.000 recién nacidos de bajo peso en Colombia, proporcionando evidencia robusta sobre los resultados clínicos del método canguro y consolidando una base de datos clínica de alto valor para investigación (Charpak & Montealegre-Pomar, 2023). No obstante, a pesar de la disponibilidad de estos datos, existe una oportunidad de investigación en el desarrollo de modelos predictivos que utilicen información del control prenatal para estimar tempranamente el riesgo de prematuridad.

En este contexto, el presente proyecto propone desarrollar y evaluar modelos de clasificación supervisada basados en variables clínicas del embarazo y del contexto materno-familiar, utilizando datos provenientes del Programa Madre Canguro. El objetivo es identificar patrones predictivos asociados al riesgo de parto pretérmino y evaluar el potencial de estos modelos como herramienta de apoyo a la toma de decisiones clínicas.

6. Metodología y enfoque propuesto.

Enfoque técnico:

El proyecto aborda dos problemas de aprendizaje automático complementarios sobre datos tabulares longitudinales de ~64.801 historias clínicas con 753 variables:

Problema 1 - Clasificación de estado nutricional a 12 meses de edad corregida: Construir modelos supervisados que clasifiquen a los sujetos en grupos de estado nutricional (Normal, Deficiente) según los tres indicadores definidos por la OMS:

- Retraso en el crecimiento: z-score talla/edad (LAZ/HAZ) < -2
- Desnutrición aguda: z-score peso/talla (WLZ/WHZ) < -2
- Bajo peso: z-score peso/edad (WAZ) < -2

Problema 2 - Identificación de factores de riesgo tempranos: Determinar qué variables de las fases iniciales del desarrollo (prenatal, nacimiento, hasta 40 semanas EG, 3 y 6 meses EC) son predictoras significativas de malnutrición a los 12 meses, con énfasis en: RCIU, RCEU, velocidad de crecimiento, tipo de alimentación y duración de la posición canguro.

Herramientas:

 **MAIA4401 - Propuesta Informacion Adicional**

7. Exploración y descripción de los datos

El dataset proviene de la base de datos clínica de la **Fundación Canguro**, que contiene historias clínicas anonimizadas de pacientes del **Programa Madre Canguro Integral (PMCI)** recolectadas durante los últimos 25 años (aprox. 1993-2024).

Distribución de variables por prefijo/categoría

Atributo	Valor
Registros (filas)	64.801 historias clínicas
Variables (columnas)	753
Formato original	SPSS exportado a XLSX
Diccionario de datos	PhETI con 634 variables documentadas, 7 hojas (README, Variables, Fases, Episodios, Temas de Interés, Prefijos)

Estructura temporal	Datos longitudinales: prenatal → nacimiento → 40 sem EG → 3m, 6m, 9m, 12m EC
----------------------------	---

Preparación de datos.

El dataset empleado para este proyecto corresponde al registro clínico del Programa Madre Canguro Integral (PMCI), con un total de 64.801 pacientes y 753 variables. A continuación se presentan los hallazgos del Análisis Exploratorio de Datos (EDA) realizado:

Variable objetivo (preterm): La variable objetivo presenta únicamente 16 valores nulos (0,02%), lo que la convierte en una variable prácticamente completa. La distribución de clases es la siguiente: 48.320 casos positivos (prematuro, 74,6%) y 16.465 casos negativos (no prematuro, 25,4%). Se evidencia un desbalance de clases con una relación aproximada de 3:1.

Calidad de los datos: El dataset presenta valores nulos con distinta distribución entre las 753 columnas. Adicionalmente, los datos provenientes de SPSS contienen la cadena '#NULL!' como representación de valores faltantes, la cual debe ser transformada a valores nulos reales durante el preprocesamiento. La distribución de nulos por columna es la siguiente:

Nivel de nulos	Número de columnas	Porcentaje del total
Sin nulos (0%)	1	0,1%
Bajo (1–25%)	261	34,7%
Medio (26–50%)	181	24,0%
Alto (51–75%)	226	30,0%
Muy alto (>75%)	84	11,2%

Preparación de datos. Con base en la exploración y el análisis de calidad, describir en detalle la propuesta para la limpieza y preparación de los datos, incluyendo las técnicas que se utilizarán.

Con base en los hallazgos del EDA, se propone la siguiente estrategia de preparación de datos:

1. Limpieza de valores nulos de SPSS: Transformar todos los valores '#NULL!' presentes en el dataset a valores nulos reales (NaN) como primer paso del pipeline.
2. Eliminación de columnas con alta proporción de nulos: Se propone eliminar las 84 columnas que presentan más del 75% de valores nulos, ya que su capacidad predictiva es limitada y su imputación introduciría un sesgo significativo.

3. Evaluación clínica de columnas con 51–75% de nulos: Las 226 columnas en este rango corresponden en su mayoría a variables de seguimiento longitudinal (mediciones a los 3, 6, 9 y 12 meses), cuyos nulos reflejan deserción del programa y no necesariamente ausencia de información. Se validará con el experto clínico cuáles de estas variables son relevantes para la predicción de prematuridad.
4. Imputación de columnas con 1–50% de nulos: Para las 442 columnas restantes con nulos en este rango se aplicarán estrategias de imputación según el tipo de variable: mediana para variables numéricas continuas, moda para variables categóricas, e imputación por KNN para variables con relaciones entre sí.
5. Tratamiento del desbalance de clases: Dado el desbalance detectado (74,6% prematuro vs. 25,4% no prematuro), se evaluarán las siguientes estrategias: (a) SMOTE (Synthetic Minority Oversampling Technique) para sobremuestreo de la clase minoritaria; (b) `class_weight='balanced'` en los algoritmos que lo soporten; (c) undersampling aleatorio de la clase mayoritaria. La elección final dependerá del impacto en las métricas de evaluación.
6. Conversión de tipos de datos: La mayoría de las columnas se encuentran en formato object debido a la presencia de valores '#NULL!'. Una vez realizada la limpieza, se convertirán al tipo numérico o categórico correspondiente.
7. Variables clave identificadas con baja proporción de nulos: Las siguientes variables son candidatas prioritarias como features del modelo dado su completitud y relevancia clínica: `gestasal` (0,02% nulos), `gestacat` (0,7%), `menosde31sem` (0,02%), `SGAprema` (3,7%), `gestasalsindecimales` (13,4%) y `edadmatcat` (1,0%).

8. Consideraciones Éticas

Impacto social y ético.

Este proyecto es de gran impacto sobre toda clase social con prelación en poblaciones vulnerables, la automatización de diagnósticos y procedimientos médicos permite la reducción de costos y aumenta la accesibilidad.

Sesgos y su mitigación.

Dada la naturaleza y calidad de los datos, estos presentan un desbalance y un tamaño de población pequeño, con base en esto se busca implementar estrategias que permitan aumentar en primera instancia la precisión del modelo dado su impacto clínico, esto se puede lograr mediante el balanceo y estratificación de los datos.

Transparencia y explicabilidad.

Con el diseño y entrenamiento del modelo se busca conservar la explicabilidad de los resultados, permitiendo entender los distintos factores y su influencia dentro de la predicción de prematuridad.

Privacidad y seguridad.

Atendiendo a las restricciones de la organización, los datos se encuentran anonimizados y su empleo está restringido únicamente a los propósitos de este proyecto.

9. Evaluación y Métricas

La evaluación de la solución se enfocará en medir (i) el desempeño predictivo de los modelos para identificar malnutrición a los 12 meses de edad corregida y (ii) la utilidad clínica/interpretabilidad de los factores de riesgo tempranos identificados, garantizando un proceso reproducible y sin fuga de información.

La solución se evaluará con un esquema train/validación/test (estratificado) y validación cruzada en entrenamiento. El test se reservará para el resultado final.

Métricas principales (clasificación desbalanceada)

- AUPRC (métrica principal).
- AUROC (métrica complementaria).
- Sensibilidad (recall), especificidad, precisión (PPV), F1 y matriz de confusión (en un umbral definido).

Selección de umbral (criterio clínico)

El umbral se elegirá en validación priorizando alta sensibilidad (minimizar falsos negativos) y reportando el trade-off con precisión/especificidad.

Calibración

- Brier score y curva de calibración para verificar que las probabilidades sean confiables.

Comparación (referencia)

- Baseline 1: clasificador “mayoritaria”.
- Baseline 2: regresión logística (modelo interpretable).

Si existe una solución previa/protocolo clínico, se reportarán sus métricas con el mismo conjunto de test para comparación directa.

Factores de riesgo e interpretabilidad

Se reportará el top de variables predictoras (p. ej., con SHAP/permutación) y su estabilidad entre folds, para sustentar los factores de riesgo tempranos.

10. Cronograma

 MAIA4401 - Propuesta Informacion Adicional

11. Bibliografía

1. Charpak, N., Ruiz, J. G., Zupan, J., et al. (2005). Kangaroo mother care: 25 years after. *Acta Paediatrica*, 94(5), 514–522.
2. Charpak, N., & Montealegre-Pomar, A. (2023). Follow-up of Kangaroo Mother Care programmes in the last 28 years: Results from a cohort of 57,154 low-birth-weight infants in Colombia. *BMJ Global Health*, 8(5).
3. Fundación Canguro. (s. f.). Documentación científica y programas del Método Madre Canguro. <https://fundacioncanguro.co/documentacion-canguro/>
4. Belaghi, R. A., et al. (2024). Prediction of preterm birth in multiparous women using logistic regression and machine learning approaches. *Scientific Reports*.
5. Charpak, N., & Montealegre-Pomar, A. (2023). Follow-up of Kangaroo Mother Care programmes in the last 28 years: results from a cohort of 57,154 low-birth-weight infants in Colombia. *BMJ Global Health*.
6. Huang, C., et al. (2024). Predicting preterm birth using electronic medical records in nulliparous women.
7. Mennickent, D., et al. (2023). Machine learning applied in maternal and fetal health: a narrative review focused on pregnancy diseases and complications. *Frontiers in Endocrinology*.
8. Yang, Q., et al. (2023). Reporting and risk of bias of prediction models based on machine learning in preterm birth: a systematic review.
9. Yu, Q. Y., et al. (2024). Predicting risk of preterm birth in singleton pregnancies using machine learning.