

Predicción de nacimiento prematuro en infantes con 7 meses de control

1. Problemática

Anualmente, se registran más de 15 millones de nacimientos pretérmino (gestación menor a 37 semanas). Paralelamente, cerca de 20 millones de recién nacidos presentan bajo peso (inferior a 2.500 g). La prematuridad y el bajo peso al nacer constituyen determinantes críticos de la morbilidad neonatal, siendo responsables de aproximadamente el 35% de los fallecimientos de recién nacidos en el mundo. Los supervivientes enfrentan un pronóstico complejo, con riesgos elevados de secuelas neurológicas, respiratorias y del desarrollo, así como predisposición a enfermedades crónicas.

El objetivo central de este proyecto es el desarrollo de un sistema de soporte al diagnóstico fundamentado en técnicas de aprendizaje automático (machine learning). Este sistema tiene la capacidad de estimar la probabilidad de un parto prematuro analizando la historia clínica del paciente hasta el séptimo mes de gestación. El resultado final es una herramienta dotada de una interfaz intuitiva, diseñada para facilitar la interacción y la toma de decisiones del especialista médico.

1.1. Pregunta de negocio

Se establece la siguiente interrogante que orienta la delineación de los objetivos, el alcance y los entregables del proyecto:

¿En qué medida es factible utilizar técnicas de aprendizaje automático (machine learning) para anticipar el nacimiento prematuro y calcular su probabilidad de ocurrencia, procesando datos provenientes del control prenatal y del contexto materno-familiar?

Si bien la pregunta se formula bajo un marco de gran generalidad, resulta fundamental para delimitar el foco central del proyecto, lo que a su vez orienta las decisiones inherentes a su desarrollo.

1.2. Objetivos

La pregunta planteada conduce a la definición del objetivo central del proyecto: desarrollar un instrumento de monitoreo con aprendizaje automático supervisado. Este sistema estará diseñado para proporcionar una visualización integral del perfil médico del paciente, conjuntamente con una estimación probabilística de parto prematuro generada por el modelo. De esta manera, se garantizará la visibilidad y la gestión eficiente de la información clínica, y se ofrecerá un indicador de probabilidad que funcione como un mecanismo de alerta temprana sobre el estado del paciente.

1.3. Alcance técnico y operativo

Conscientes de las limitaciones inherentes en los ámbitos técnico y operativo, es fundamental delimitar el alcance del proyecto para lograr la eficiencia en la administración de los recursos, permitiendo la consecución del objetivo de la manera más satisfactoria y la entrega de un producto funcional. A continuación se listan las generalidades del producto esperado:

1. Establecer el almacenamiento y versionamiento del código a través de repositorios GitHub y Data Version Control (DVC) conforme a las restricciones de confidencialidad.
2. Uso del historial clínico de pacientes bajo las restricciones necesarias para el tratamiento de datos sensibles.
3. Definir el proceso de exploración y limpieza de datos.
4. Construir un modelo supervisado de clasificación binaria para predecir prematurez.
5. Establecer una primera línea base (baseline) y preparar el pipeline para entrenamiento y validación.
6. Construir una API y una interfaz gráfica para la interacción del usuario con los modelos.

1.4 Conjunto de datos

El conjunto de datos se constituye como una base histórica, que comprende aproximadamente 70.000 expedientes clínicos anonimizados, bajo la administración de la Fundación Canguro. Dicho archivo incorpora información relativa al control prenatal, el entorno familiar, los pormenores del nacimiento y el seguimiento clínico subsiguiente.

Con el objetivo de acelerar la exploración inicial y el diagnóstico de la calidad de los datos, se procedió a trabajar con una muestra de 10.000 registros 171 variables, extraída del archivo en formato Excel que contiene 70.000 registros y un total de 753 variables.

1.4.1. Nota de confidencialidad

Atendiendo a las restricciones de la organización, los datos se encuentran anonimizados y su empleo está restringido únicamente a los propósitos de este proyecto.

1.5 Cambios

Con el propósito de cambiar el enfoque de este documento de planteamiento hacía desarrollo, se hizo un resumen del contenido de la problemática para dar espacio a contenido orientado a infraestructura de código y modelado. Como consecuencia se crearon nuevas secciones que contienen el proceso de modelado y los resultados obtenidos, junto con la construcción de la arquitectura de la aplicación.

2. Modelado

Se hizo entrenamiento de modelos con una muestra de alrededor de 10.000 registros con 171 variables, dividido en entrenamiento y test con una proporción de 80 a 20 respectivamente. En la figura 1 observamos la instancia utilizada para el entrenamiento de los modelos.




Figura 1. Instancia EC2 de tipo t2.medium para la instalación de MLFlow.

Con la infraestructura establecida podemos hacer uso de esta para hacer el entrenamiento de los modelos de una forma sencilla, en la figura 2 observamos los modelos entrenados dentro de la instancia versionados a través de MLFlow.




Figura 2. Modelos de entrenamiento dentro de la instancia EC2 y MLFlow.

Dado la forma del conjunto de datos y el alcance del proyecto, los modelos de entrenamiento supervisados seleccionados fueron la Regresión Logística, Random Forest y Gradient Boosting. Con esto se logra evaluar un espectro entre modelos explicables y de mayor complejidad.

2.1. Resultados

Con los modelos entrenados procedemos a realizar predicciones sobre el conjunto de datos de prueba. Con esto obtenemos la Figura 3, que visualiza las matrices de confusión de las predicciones realizadas sobre las reales. Notamos que, a diferencia de la Regresión Logística, los modelos Random Forest y Gradient Boosting presentan un mayor número de falsos positivos (Error tipo I), esto representa un gran problema dado la aplicación de los modelos dentro del mundo médico.




Figura 3. Matrices de confusión de las predicciones realizadas por los tres modelos.

Por otro lado, con la Figura 4 observamos el comportamiento del balance entre precisión y recall, notamos que podemos maximizar la precisión sin tener un impacto crítico en el recall, esto es positivo dado que necesitamos priorizar la minimización de los falsos positivos predichos por el modelo.




Figura 4. Curvas de precision-recall (izquierda) y ROC (derecha) para los tres modelos entrenados.

2.1.1. Relevancia de variables

Con los modelos entrenados podemos hacer una revisión de las variables que tienen una mayor relevancia sobre la predicción. Con base en la Figura 5, podemos identificar que la escolaridad del padre es la variable más relevante sobre la predicción, algo que coincide para ambos modelos presentados.




Figura 5. Relevancia de las variables para los modelos Gradient Boosting (izquierda) y Random Forest (derecha).

2.2. Evaluacion

Posterior al entrenamiento de los modelos se procedió con la evaluación de su desempeño haciendo uso del conjunto de datos de evaluación. Este desempeño es medido a través de las métricas de la tabla 1 junto con el valor respectivo a cada modelo.

Métrica	Modelo
---------	--------

	Logistic Regression	Random Forest	Gradient Boosting
Accuracy	0.7114	0.767	0.7768
Balanced Acc	0.7051	0.7339	0.7345
F1-Score	0.7607	0.8231	0.835
ROC-AUC	0.7789	0.8096	0.813
CV F1 (mean)	0.7676	0.8234	0.8302
CV F1 (std)	0.0105	0.01	0.0049

Tabla 1. Comparativo entre las métricas definidas para la medición del desempeño de los modelos.

2.3. Conclusiones

A partir de la tabla 1 podemos observar que el modelo de regresión logística obtiene el peor desempeño entre los tres modelos, seguido por Random Forest y Gradient Boosting. Con esto identificamos un dilema de explicabilidad-desempeño, en donde el modelo con la mejor interpretabilidad (Regresión Logística) supone una pérdida en el desempeño de las métricas evaluadas, y el modelo con el mejor desempeño (Gradient Boosting) supone una menor interpretabilidad.

Por lo tanto, se concluye que Gradient Boosting es el modelo ideal para el proceso de predicción y selección de relevancia de las características dado que obtiene el mejor desempeño en las distintas métricas. Esto no descarta la posibilidad de hacer uso de los otros modelos para el proceso de interpretabilidad médica.

Por último, encontramos que para todos los modelos la métrica Balanced Accuracy resulta ser menor que el Accuracy, esto indica un desbalance de clases, por lo que resulta necesario evaluar el desempeño a través de las métricas F1, AUC y Balanced Accuracy para asegurar un desempeño no sesgado.

3. Infraestructura

El repositorio está estructurado de la siguiente forma para asegurar una ejecución adecuada de la aplicación y legibilidad del código:

Python

PrematureBirth/

```
├─ __init__.py
├─ app/
│   └─ api/
│       ├── __init__.py
│       ├── api.cpython-313.pyc
│       └─ definition.cpython-313.pyc
│   ├── config.py
│   ├── definition.py
│   ├── main.py
│   └─ schemas/
│       ├── __init__.py
│       └─ predict.py
└─ dashboard/
    ├── README.md
    └─ dashboard.py
```

```

|       ├── dashboard_data.xlsx
|       └── requirements.txt
├── main.py
└── model/
    ├── __init__.py
    ├── data/
    ├── exploration_output.txt
    ├── malnutrition_model.py
    ├── notebooks/
    │   └── Malnutricion.ipynb
    ├── output/
    ├── pipeline.py
    └── predict.py

```

Bajo esta estructura encontramos dos carpetas principales que dividen el proceso de modelado del desarrollo de la API y la interfaz gráfica.

3.1. Modelado

El modelado contiene el pipeline de procesamiento y predicción de los datos, para iniciar el servidor de MLFlow se ejecuta el siguiente comando:

```

Shell
mlflow server \
  --host 0.0.0.0 \
  --port 8050 \
  --allowed-hosts "*" \
  --backend-store-uri sqlite:///mlflow.db \
  --default-artifact-root ./mlruns

```

El parámetro `--allowed-host` permite la conexión desde cualquier IP para las versiones 3.x de MLFlow. Mientras este se encuentra en ejecución podemos llamar los comandos para realizar los experimentos con cualquier modelo definidos en el archivo `malnutrition_model.py`

3.2. API

La API se encarga de la conexión entre los modelos y la aplicación presentada, esta gestiona el proceso de predicción. En la Figura 6 se encuentra una visualización de la API creada para gestionar la predicción de los modelos




Figura 6. Captura de la página de la API para la predicción de la prematuridad de los fetos.

En esta se pueden definir los parámetros de entrada para los modelos y se realiza una predicción haciendo uso de la versión configurada de estos.

3.3. Dashboard

3.3.1. Visualización Pantalla Principal – Vista Poblacional

Con el propósito de materializar la propuesta de solución y facilitar la toma de decisiones clínicas, se implementó una vista poblacional en un dashboard interactivo desarrollado con Python Dash. Esta pantalla permite caracterizar de forma agregada la población atendida, identificando patrones generales asociados a factores maternos, neonatales y antecedentes clínicos que se relacionan con el riesgo de prematuridad y complicaciones.

Dado que el proyecto se encuentra en una fase inicial de desarrollo y validación, actualmente la fuente de datos se gestiona mediante archivos Excel, los cuales corresponden a datos reales del proyecto. Esta decisión permite acelerar el prototipado de la interfaz, validar la coherencia de indicadores con el equipo y ajustar visualizaciones antes de integrar una base de datos o un flujo de ingesta automatizado.

La vista poblacional ofrece una lectura rápida del estado general del proyecto mediante tarjetas KPI, una tabla de indicadores con formato condicional y gráficos que resumen variables críticas como lactancia materna exclusiva, complicaciones prenatales y distribuciones demográficas (p. ej., edad gestacional, sexo y edad materna). En conjunto, esta pantalla funciona como un panel de monitoreo que apoya el análisis exploratorio y la priorización clínica, alineado con la problemática del proyecto: la prematuridad y el bajo peso al nacer como determinantes clave de morbilidad neonatal.

3.3.2. Visualización Pantalla Usuario – Vista por Paciente

Adicionalmente, se implementó una vista individual por paciente, diseñada para que el personal médico consulte de forma estructurada la información clínica relevante del caso y su evolución. Esta pantalla responde a la necesidad de contar con una herramienta que consolide variables dispersas del control prenatal y del contexto materno-familiar, apoyando la evaluación del riesgo y la decisión clínica.

En esta versión del prototipo, la vista por paciente se alimenta con datos reales, lo cual permite validar la experiencia de usuario y la pertinencia clínica de los elementos presentados (perfil, factores de riesgo y seguimiento). La interfaz incluye un selector de paciente, un panel con información básica (edad gestacional, peso al nacer, APGAR, lactancia), un resumen de factores de riesgo y visualizaciones de seguimiento (por ejemplo, evolución de z-scores y métricas de hospitalización).

Esta vista está alineada con la pregunta de negocio del proyecto, ya que prepara el componente visual donde posteriormente se integrará el modelo supervisado de machine learning, cuyo objetivo será estimar la probabilidad de nacimiento prematuro usando variables del control prenatal y del contexto materno-familiar, funcionando como un mecanismo de alerta temprana y soporte al diagnóstico.

Abajo se adjuntan dos capturas de pantalla de cada página.




Figura 7. Visualización Pantalla Principal - Vista Poblacional.




Figura 8. Visualización Pantalla Usuario - Vista por Paciente.

4. Configuración

Para garantizar la trazabilidad y el control de versiones durante el ciclo de desarrollo, se ha gestionado un repositorio en GitHub cuyo versionado se manejará a través de Data Version Center (DVC).

4.1. Repositorios

4.1.1. GitHub

El repositorio de GitHub se encuentra alojado bajo una cuenta institucional, lo que facilita el almacenamiento centralizado y el intercambio seguro de información entre colaboradores y evaluadores. El acceso a este está disponible en el siguiente enlace:

https://github.com/fabianmejiaandes/proyecto_desarrollo_soluciones_canguro.git

En la Figura 9 se observa la página principal del repositorio con su respectivo contenido.




Figura 9. Página de inicio en GitHub del microproyecto.

Para garantizar la confidencialidad y la protección de la información sensible, se ha establecido un esquema de acceso restringido. De esta manera, la visualización y gestión de los datos están limitadas exclusivamente al equipo de desarrollo, al experto colaborador y a los evaluadores designados, evitando así cualquier divulgación no autorizada.

4.1.2. AWS

El alojamiento cloud de los datos se hará a través de un bucket de AWS en S3, el cual cuenta con un usuario IAM compartido entre todos los integrantes para garantizar el acceso. En la Figura 10 se encuentra la visualización de dicho bucket dentro de la página de AWS.


```
PS C:\Users\lfabi\OneDrive\Documents\developer\uniandes\desarrollo_proyectos\proyecto_desarrollo_soluciones_canguro> aws configure
AWS Access Key ID [None]: 
AWS Secret Access Key [None]: 
Default region name [None]: 
```

Figura 13. Proceso de configuración de llaves de acceso a AWS en la terminal.

```
PS C:\Users\lfabi\OneDrive\Documents\developer\uniandes\desarrollo_proyectos\proyecto_desarrollo_soluciones_canguro> dvc remote add -d storage s3://dvc-data-canguro/datasets
Setting 'storage' as a default remote.
PS C:\Users\lfabi\OneDrive\Documents\developer\uniandes\desarrollo_proyectos\proyecto_desarrollo_soluciones_canguro> git status
On branch main
Your branch is up to date with 'origin/main'.

Changes not staged for commit:
  (use "git add <file>.." to update what will be committed)
  (use "git restore <file>.." to discard changes in working directory)
        modified:   dvc/config
```

Figura 14. Estado de la rama previo al commit de los cambios en la terminal.

Finalmente, se corroboró la carga satisfactoria de los datos dentro del bucket de S3, lo cual certifica la implementación exitosa de la totalidad de las configuraciones (Figura 15).




Figura 15. Validación de la carga de los datos dentro del bucket de S3.

5. Colaboradores

El siguiente documento y el desarrollo del proyecto se llevó a cabo por los siguientes integrantes:

- Stiven Calderon Rojas
- Juan Andres Guzmán Pineda
- Hernando Jose Jimenez
- Leison Fabian Mejia Garcia

En colaboración con Jose Tiberio Hernandez como experto en el tema. A continuación se encuentra la responsabilidad de cada integrante para el desarrollo de este documento:

Actividad	Responsable
Pregunta de negocio	Todos
Manejo de datos y modelado	Leison Fabian Mejia, Hernando Jose Jimenez
Diseño arquitectónico a alto nivel: API de predicción e interfaz	Stiven Calderon Rojas, Juan Andres Guzmán
Redacción del documento	Todos
Repositorios	Todos

Tabla 1. Responsables de cada actividad dentro del desarrollo de la primera entrega del proyecto.

6. Referencias

1. Charpak, N., Ruiz, J. G., Zupan, J., et al. (2005). *Kangaroo mother care: 25 years after*. Acta Paediatrica, 94(5), 514–522.

2. Charpak, N., & Montealegre-Pomar, A. (2023). *Follow-up of Kangaroo Mother Care programmes in the last 28 years: Results from a cohort of 57,154 low-birth-weight infants in Colombia*. *BMJ Global Health*, 8(5).
3. Fundación Canguro. (s. f.). *Documentación científica y programas del Método Madre Canguro*. <https://fundacioncanguro.co/documentacion-canguro/>